

Together AI 콘솔 UI/UX · 기능 분석 보고서

메이머스트(MAYMUST) AI 서빙 플랫폼 제품 개발 참고용

작성일: 2026-06-23 (Asia/Seoul) 조사 방식: 브라우저 직접 접속 관찰

대상: together.ai (공개 마케팅) + api.together.ai (로그인 콘솔, read-only 계정)

1. 조사 개요

Together AI는 독립 추론 서빙 사업자 중 매출·인지도 선두 그룹에 속하며, 카탈로그 → 엔드포인트로 이어지는 셀프서비스 플로우를 표준화한 사례로 평가된다. 본 보고서는 메이머스트 AI 서빙 플랫폼의 UI/UX 및 기능 설계 시 벤치마크로 활용하기 위해, 실제 화면을 직접 접속하여 정보구조·화면 구성·제공 기능을 정리한 것이다.

조사 범위와 한계

- 공개 영역(로그인 불필요): 마케팅 사이트의 제품 네비게이션과 추론 하위 분류까지 확인.
- 콘솔 영역(로그인 필요): read-only 모드 계정으로 접속하여 사이드바의 13개 화면을 직접 관찰. 입금 전 상태라 실제 잡 실행/배포 결과 화면은 빈(empty) 상태로 표시됨.
- 스크린샷은 브라우저 세션에서 캡처되어 채팅 대화에 보존되어 있으며, 본 문서에는 화면별 구조·기능 분석을 텍스트로 정리하였다.
- 계정·결제·API 키 등 민감정보는 보고서에서 제외하였다.

* 본 자료의 외부 링크·제품 라인업·가격은 관찰 시점(2026-06) 기준이며, 제품 개발에 반영하기 전 공식 사이트에서 재확인 필요.

2. 정보구조(IA) · 네비게이션

2.1 마케팅 사이트 (together.ai)

상단 글로벌 네비게이션은 7개 축으로 구성된다: Inference / Compute / Model Shaping / Research / Developers / Company / Pricing. 'Build what's next on the AI Native Cloud'를 핵심 메시지로, 'Full-stack AI platform'으로 포지셔닝한다. 신뢰 고객사로 Cohere, DeepMind, LG AI Research, ElevenLabs, Jasper, Salesforce, Leonardo.AI 등을 노출한다.

Inference 메뉴 하위 분류: Serverless Inference(API형 고성능 추론) · Batch Inference(배치 워크로드) · Dedicated Model Inference(전용 하드웨어) · Dedicated Container Inference(커스텀 모델) + Model library(오픈소스 모델 카탈로그). 드롭다운 우측에 실제 모델 카드 미리보기(MiniMax, Qwen3.5, GLM-5, Kimi K2.5, GPT-OSS 등)를 함께 노출하여 메뉴 자체가 카탈로그 진입점 역할을 한다.

2.2 콘솔 (api.together.ai) 사이드바


항목	내용
상단 공통	Dashboard · Models · Playground (프로젝트 선택기 'Default Project', 다크모드 토글, 알림/도움말 아이콘)
Inference 그룹	Endpoints(전용 엔드포인트) · Batch jobs · Containers
Model Shaping 그룹	Fine-tuning jobs · Evaluations
하단 단독	GPU Clusters · Analytics · Files · Settings

시사점: 마케팅 IA와 콘솔 IA가 'Inference / Model Shaping'이라는 동일한 축으로 정렬되어 있다. 즉 영업/마케팅 언어와 제품 내부 구조가 한 어휘 체계를 공유한다. 우리 도메인 온톨로지(Project/Dataset/BaseModel/Experiment/ModelArtifact/Deployment)도 외부 소구 메시지와 콘솔 메뉴가 같은 어휘를 쓰도록 정렬할 가치가 있다.

3. 화면별 상세 분석

3.1 Dashboard — Developer Quickstart

URL: api.together.ai/



▲ 화면 구조도 (와이어프레임 · 실제 화면 관찰 기반 재구성)

레이아웃 / 구성:

- 상단에 read-only 안내 배너(입금 유도). 'Developer Quickstart' 영역이 첫 화면 중심.
- 즉시 실행 가능한 코드 스니펫 박스(Python / TypeScript / curl 토글, 복사 버튼). 기본 예시 모델 openai/gpt-oss-20b.
- 'Do more with your APIs' 카드 그리드: Manage API keys, Check API reference 등 다음 액션 안내.

제공 기능:

- 언어별 코드 스니펫 즉시 제공 및 복사
- API 키 관리·API 레퍼런스 바로가기 카드
- docs 로 연결되는 'Read the docs' 버튼


UX 포인트:

- 신규 사용자가 로그인 직후 '첫 API 호출까지 수 분' 경험을 하도록 코드 우선(code-first)으로 설계. 빈 대시보드 대신 즉시 실행 코드를 보여줌.

우리 제품 매핑: 온보딩 화면을 '빈 상태 + CTA'가 아니라 '복붙 가능한 첫 호출 코드'로 채우는 패턴은 개발자 페르소나(ML Engineer 우선) 대상 첫인상 설계에 그대로 차용 가능.

3.2 Models — 모델 카탈로그

URL: api.together.ai/models



▲ 화면 구조도 (와이어프레임 · 실제 화면 관찰 기반 재구성)

레이아웃 / 구성:

- 상단 'Featured Models' 카드 4 종(GLM 5.2, MiniMax M3, Kimi K2.7 Code, Deepseek V4 Pro 등).
- 하단 'Browse Models' 테이블 + 좌측 필터 패널.
- 우상단 'Deploy custom model' / 'Upload a model' 버튼.

제공 기능:

- 모델 카드: 제공자(author), 기능 태그(Chat·JSON Mode·Tool Calling·Multi-Modal), Serverless 배지, 업로드일, 파라미터 규모(예: 436.2B), 가격(입력/출력 per 1M, Cached Input 별도 표기)
- 좌측 필터: Deployment(Serverless / Dedicated), Input modalities 등 패킷 필터
- 테이블 컬럼: Model Name / Author / Category, 정렬 지원, 행별 : 액션
- All models / My models 탭 분리, 검색, 'Compare'(모델 비교)


UX 포인트:

- 가격을 입력·출력·캐시입력 3 종으로 분해해 카드 전면에 노출 → 비용 투명성
- 'New' 배지로 신규 모델 강조
- 카드(탐색) ↔ 테이블(정밀 비교)의 이중 뷰

우리 제품 매핑: 우리 카탈로그의 핵심 레퍼런스. 모델 카드에 '기능 태그 + 배포유형 배지 + 분해된 단가'를 표준 메타데이터로 두고, Serverless/Dedicated 필터를 1 차 패킷으로 삼는 구조를 권장.

3.3 Playground

URL: api.together.ai/playground/...



▲ 화면 구조도 (와이어프레임 · 실제 화면 관찰 기반 재구성)

레이아웃 / 구성:

- 중앙: System Prompt 입력줄 + 대화 영역 + 하단 입력창(첨부·전송).
- 우측: 파라미터 패널.
- 상단: 모드(Chat) 표시, 모델 칩, 'API view' 버튼.

제공 기능:

- 파라미터: Output Length, Temperature(슬라이더, UNSET 토글), Safety Model, Reasoning(Model Default), Response Format(Text/JSON 등), Functions(+ Add Function), Sampling
- Presets 저장/적용
- 모델 셀렉터로 즉시 모델 교체
- 'API view'로 현재 설정을 코드로 즉시 export


UX 포인트:

- 슬라이더 옆 'UNSET'으로 '미설정=모델 기본값' 상태를 명시 → 초보자도 안전
- 함수 호출(tool)·Safety Model 을 UI 1 급 요소로 노출
- 대화 테스트 → 그대로 코드화하는 '체험-코드' 한 클릭 전환

우리 제품 매핑: Playground 는 '카탈로그에서 고른 모델을 즉시 시험 → API view 로 코드 추출'의 연결 고리. 우리도 모델 상세에서 Playground 로, Playground 에서 코드/엔드포인트로 이어지는 단일 동선을 설계할 것.

3.4 Dedicated Endpoints — 목록

URL: api.together.ai/endpoints



▲ 화면 구조도 (와이어프레임 · 실제 화면 관찰 기반 재구성)

레이아웃 / 구성:

- 헤더 'Dedicated endpoints' + 설명, 우상단 '+ New dedicated endpoint'.
- 검색창 + 테이블(Name / Status / Hardware / Pricing, 정렬).
- 빈 상태: 일러스트 + 'Get started' CTA.
- 하단 'Scale Inference Without Limits' 영업 카드(Contact sales).

제공 기능:

- 전용 엔드포인트 목록/검색/정렬
- 상태(Status)·하드웨어·가격을 한 행에서 확인
- 빈 상태에서 생성 유도, 대규모는 영업 연결 분기

UX 포인트:

- 빈 상태에도 '무엇을 만드는 곳인지' 설명과 단일 CTA를 둬
- 셀프서비스(소규모) ↔ 영업(엔터프라이즈) 두 경로를 한 화면에서 분기

우리 제품 매핑: 엔드포인트 목록 화면은 'Name/Status/Hardware/Pricing' 4 컬럼이 최소 핵심. 우리 Deployment 목록도 상태·할당 GPU·비용을 한 줄에서 보이게 할 것.

3.5 Create new endpoint — 생성 폼

URL: api.together.ai/endpoints/configure

together.ai

Default Project ▼

△ You're currently in read-only mode. Make an initial deposit to unlock full access.

Create new endpoint

Home > Dedicated endpoints > Create new endpoint

Model

Select a model ▼

Display name

Set a name

Hardware

Select a model first ▼

Min replicas

1 ▼

Availability zone

No preference ▼

Auto-shutdown

Select an option ▼

Speculative decoding

No preference ▼

Max replicas

1 ▼

Summary

Choose a model and hardware to get a cost estimate

Confirm & deploy

모델→하드웨어 의존 활성화
오토스케일 + 실시간 비용 추정

▲ 화면 구조도 (와이어프레임 · 실제 화면 관찰 기반 재구성)

레이아웃 / 구성:

- 브레드크럼: Home > Dedicated endpoints > Create new endpoint.
- 폼 필드 + 우측 'Summary' 카드(비용 추정 + 'Confirm & deploy').
- Confirm & deploy 는 입력 전 비활성화.

제공 기능:

- Model 선택
- Display name
- Availability zone
- Hardware(모델 선택 후 활성화)
- Auto-shutdown
- Min replicas / Max replicas(오토스케일)
- Speculative decoding
- Summary: 모델·하드웨어 선택에 따른 실시간 비용 추정


UX 포인트:

- '모델을 먼저 고르면 하드웨어가 활성화'되는 의존적 폼 → 잘못된 조합 방지
- Summary 카드가 항상 보이며 비용을 선반영 → 배포 전 비용 예측
- 핵심 옵션만 노출하고 나머지는 기본값(No preference)으로 단순화

우리 제품 매핑: 이 폼이 우리 엔드포인트 생성 UX 와 가장 직접 매핑된다. '모델 → 하드웨어(GPU) → Min/Max replica → 자동 종료 → 비용 요약 → 배포'의 순서와 의존 활성화, 실시간 비용 추정을 그대로 채택 검토. Speculative decoding 을 1 급 옵션으로 둔 점도 참고(우리는 Dynamo disaggregation 을 같은 위치에 노출 가능).

3.6 Fine-tuning jobs

URL: api.together.ai/fine-tuning



▲ 화면 구조도 (와이어프레임 · 실제 화면 관찰 기반 재구성)

레이아웃 / 구성:

- 헤더 'Fine-tuning' + '+ New fine-tuning job'.
- 검색 + 상태 필터(All statuses) + 메서드 필터(All methods).
- 테이블: Job Id / Base Model / Suffix / Type / Method / Status.
- 빈 상태 CTA + 'We're here to help'(예약 플랜 영업) 카드.

제공 기능:

- 파인튜닝 잡 목록·검색·상태/메서드 필터
- Base Model·Suffix·Method·Status 컬럼
- 신규 잡 생성 진입(생성 폼은 5장에서 인터랙션 확인)


UX 포인트:

- 잡을 '상태'와 '메서드' 두 축으로 필터 → 운영 중 다건 관리 고려
- 결과물에 Suffix 를 부여해 사용자 명명 모델로 관리

우리 제품 매핑: 학습 잡 목록 패턴(Job Id/Base Model/Method/Status)은 우리 Experiment·PyTorchJob 목록 화면에 대응. Suffix 로 산출물 모델을 명명·추적하는 방식은 ModelArtifact 네이밍에 참고.

3.7 Analytics Dashboard

URL: api.together.ai/analytics



▲ 화면 구조도 (와이어프레임 · 실제 화면 관찰 기반 재구성)

레이아웃 / 구성:

- 탭: Usage / Errors.
- 컨트롤: Group By(Model 등) · 기간(24) · 단위(Hours) · Filters.
- 메트릭 카드 그리드(2 열): 각 카드에 시계열 라인 차트 + 집계 방식 라벨.

제공 기능:

- Requests(Count) / Tokens per second(Mean) / Input tokens(Sum) / Output tokens(Sum) 등 핵심 추론 지표
- Group By(모델별 등)·기간·시간단위 변경
- Usage 와 Errors 분리 뷰
- Filters 로 세분화


UX 포인트:

- 카드마다 '집계 방식(Count/Mean/Sum)'을 명시 → 지표 해석 모호함 제거
- 시계열 기본 + 상단 단일 수치 동시 표기

우리 제품 매핑: Modal 식 메트릭 시각화와 같은 방향. 우리 자체 UI(Prometheus 직접 쿼리)의 추론 레이어 대시보드에 Requests·TPS·In/Out tokens 를 기본 카드로 두고, Dynamo 의 TTFT/ITL 히스토그램을 추가 카드로 엮는 구성을 권장. 집계 방식 라벨 표기 패턴은 그대로 채택.

3.8 Batch jobs

URL: api.together.ai/batch-jobs



▲ 화면 구조도 (와이어프레임 · 실제 화면 관찰 기반 재구성)

레이아웃 / 구성:

- 헤더 'Batch jobs' + 설명, 우상단 '+ Create batch job'.
- 테이블: ID / Input file / Model / Status.
- 빈 상태 'Get started' + 'Scale Inference Without Limits' 영업 카드.

제공 기능:

- 대량 요청을 비동기로, 실시간 API 대비 할인가에 처리
- Files 에 올린 입력 파일 + 모델을 지정해 배치 잡 생성
- 잡별 상태 추적


UX 포인트:

- 빈 상태에도 설명 + 단일 CTA
- 대규모는 영업(Contact sales)으로 분기

우리 제품 매핑: 우리 배치 추론 경로에 대응. Files(데이터) → Batch job(모델+입력 파일) → Status 추적의 동선과, '비동기 처리 = 비용 절감' 메시지를 가격 정책 설계에 참고.

3.9 Containers — Deploy container

URL: api.together.ai/containers



▲ 화면 구조도 (와이어프레임 · 실제 화면 관찰 기반 재구성)

레이아웃 / 구성:

- 헤더 'Deploy container' + 설명.
- 3 단계 온보딩 카드(① Set API key → ② Add config → ③ Deploy to production) + 'Deploy via CLI'.
- 'List of deployments' 테이블: Name / Status / Image / Scaling / GPU / Created At.
- 'Custom deployments — Contact Sales to access' 게이팅 카드.

제공 기능:

- 커스텀 코드·모델·추론 엔진을 컨테이너로 배포
- CLI/SDK 기반 배포·업데이트
- 배포별 이미지·스케일링·GPU·상태 추적


UX 포인트:

- CLI 우선 워크플로(콘솔은 조회 중심)
- 커스텀 추론 엔진은 엔터프라이즈 영업 게이팅

우리 제품 매핑: 우리 BentoML 패키징 + Dynamo 컨테이너 배포에 가장 직접 대응. 'Image / Scaling / GPU' 컬럼을 우리 Deployment 목록 메타데이터로 채택. 단 Together 는 커스텀 엔진을 영업 게이팅하는 반면, 우리는 셀프서비스로 개방할 수 있는 차별점이 있다.

3.10 Evaluations

URL: api.together.ai/evaluations



▲ 화면 구조도 (와이어프레임 · 실제 화면 관찰 기반 재구성)

레이아웃 / 구성:

- 헤더 'Evaluations' + 설명, 우상단 '+ New evaluation'.
- 테이블: Name / Status / Dataset / Type / Date initiated (Status·Type 필터).
- 빈 상태 'Get started'.

제공 기능:

- 데이터셋 + 평가 유형(Type)을 묶어 평가 실행/추적
- 상태·유형 기준 필터링
- 파인튜닝 잡 목록과 동일한 '필터 + 테이블' 패턴


UX 포인트:

- 잡 계열 화면과 일관된 IA
- Dataset 을 평가의 1 급 입력으로 노출

우리 제품 매핑: 우리 온톨로지의 Experiment 옆에 둘 평가 레이어. Dataset 을 1 급 입력으로 묶어 평가를 추적하는 구조를 채택하면 학습-평가-배포가 한 데이터 계보(lineage)로 이어진다.

3.11 GPU Clusters

URL: api.together.ai/clusters



▲ 화면 구조도 (와이어프레임 · 실제 화면 관찰 기반 재구성)

레이아웃 / 구성:

- 헤더 'Together GPU Clusters' + Cloud Console/CLI(Mac·Linux) 안내.
- 탭: Clusters / Cluster Storage. 우상단 'Create cluster'.
- 테이블: NAME / TYPE / OWNER / PROVISION AT / RESERVATION ENDS / MACHINES / REGION / STATUS.
- 빈 상태 'Create a cluster' 또는 'Contact Sales'.

제공 기능:

- 전용/베어메탈 GPU 클러스터 예약·관리
- Cluster Storage 를 별도 탭으로 분리
- 콘솔 + CLI 이중 제어


UX 포인트:

- 예약 기간(RESERVATION ENDS)·머신 수(MACHINES)·리전(REGION)을 테이블 1 급 컬럼으로 가시화
- 소유자(OWNER)·타입(TYPE) 단위 멀티테넌시

우리 제품 매핑: 귀하의 kubeadm 베어메탈 GPU 클러스터 작업과 가장 직접 닿는 화면. 'RESERVATION ENDS / MACHINES / REGION' 같은 예약·용량 메타를 우리 클러스터 뷰에 도입하고, Cluster Storage 를 별 탭으로 분리한 IA 를 참고할 만하다.

3.12 Files

URL: api.together.ai/files



▲ 화면 구조도 (와이어프레임 · 실제 화면 관찰 기반 재구성)

레이아웃 / 구성:

- 헤더 'Files' + 설명, 우상단 '+ Upload File'.
- 검색창 + 테이블: File ID / Filename / Status / Size.
- 빈 상태 안내.

제공 기능:

- 입력 파일 업로드/검색/관리
- 파일별 상태·용량 표기
- 파인튜닝·배치·평가가 공유하는 중앙 저장소


UX 포인트:

- 단순·일관된 저장소 패턴
- 상태(Status)로 처리 단계 가시화

우리 제품 매핑: 우리 Dataset 엔티티의 물리 백킹에 해당. 파인튜닝/배치/평가가 동일 파일 저장소를 공유하는 구조이므로, Dataset 을 단일 소스로 두고 각 잡이 참조하도록 설계.

3.13 Settings (Account · Organization · Project)

URL: api.together.ai/settings/profile



▲ 화면 구조도 (와이어프레임 · 실제 화면 관찰 기반 재구성)

레이아웃 / 구성:

- 좌측 3 계층 서브 네비게이션 + 우측 폼.
- Account: Profile · SSH Key · Integrations.
- Organization: General · Project List · Members · Billing · Cost Analytics.
- Project: General · API Keys · Collaborators · Cost Analytics.

제공 기능:

- 계정/조직/프로젝트 3 계층으로 권한·과금 범위 분리
- Billing·Cost Analytics 를 조직 레벨에, API Keys·Collaborators·Cost Analytics 를 프로젝트 레벨에 배치
- SSH Key·Integrations 로 외부 연동 관리
- Username 이 model·job·endpoint 이름에 사용됨(네이밍이 계정명에 종속)

UX 포인트:

- 과금 가시성(Cost Analytics)을 조직·프로젝트 양 레벨에 중복 제공
- API 키를 프로젝트 스코프로 격리

우리 제품 매핑: 멀티테넌트 거버넌스 설계의 핵심 레퍼런스. Cost Analytics 를 조직·프로젝트 양 레벨에 둔 점, API Key 를 프로젝트 스코프에 격리한 점은 우리 Project/Org 권한 모델에 그대로 채택 검토. (개인정보 필드는 본 보고서에서 제외)

4. Settings 상세 화면 (Account · Organization · Project)

Settings 는 계정/조직/프로젝트 3 계층 거버넌스로 구성된다. 과금·데이터정책·구성원은 조직(Organization) 레벨에, API 키·협업자·작업공간은 프로젝트(Project) 레벨에 분리 배치되며, Cost Analytics 는 양 레벨에 중복 제공된다. 아래 12 개 하위 화면을 직접 관찰해 정리했다. (개인정보·키·결제 값은 모두 제외)

4.1 Account › Profile

URL: api.together.ai/settings/profile

Default Project ▼

ACCOUNT

- Profile
- SSH Key
- Integrations

ORGANIZATION

- General
- Project List
- Members
- Billing
- Cost Analytics

PROJECT (Default)

- General
- API Keys
- Collaborators
- Cost Analytics

Profile

Name

(redacted)

Email

(redacted)

Username (required)

✱ model:job:endpoint 이름에 사용

Company email

hello@example.com

What best describes your role?

▼

Update profile

기능 / 필드: Name·Email(잠금), Username(필수, 한 번만), Company email, 역할/가입목적/단계 설문, Update.

매핑: Username 이 model:job:endpoint 이름에 쓰이므로 네이밍 규칙을 계정 식별자에 연동하는 설계.

4.2 Account › SSH Key

URL: api.together.ai/settings/ssh-key

Default Project ▼

- ACCOUNT
 - Profile
 - SSH Key**
 - Integrations
- ORGANIZATION
 - General
 - Project List
 - Members
 - Billing
 - Cost Analytics
- PROJECT (Default)
 - General
 - API Keys
 - Collaborators
 - Cost Analytics

SSH Key

GPU 클러스터 고객용 SSH 키 관리

△ Login name은 한 번만 설정 가능 — 신중히 선택

Login Name

myname

Public SSH key

RSA...

Update

기능 / 필드: Login Name(한 번만 설정) + Public SSH key(RSA) + Update. GPU 클러스터 고객 대상.

매핑: GPU Clusters 접속 인증과 연결. 우리 베어메탈 클러스터 접근키 관리에 대응.

4.3 Account › Integrations

URL: api.together.ai/settings/integrations

Default Project ▼

- ACCOUNT
 - Profile
 - SSH Key
 - Integrations**
- ORGANIZATION
 - General
 - Project List
 - Members
 - Billing
 - Cost Analytics
- PROJECT (Default)
 - General
 - API Keys
 - Collaborators
 - Cost Analytics

Integrations

Manage your integrations

Vercel

Sync API keys into Vercel Environment Variables

Not connected

Connect

Hugging Face Hub

Set HF API key to access models directly

Not connected

Connect

기능 / 필드: Vercel(API 키를 Vercel 환경변수로 동기화), Hugging Face Hub(HF 키로 모델 접근). 각 Connect + 연결상태.

매핑: 외부 생태계 연동을 계정 레벨에 모음. 우리도 HF Hub·CI 연동을 동일 위치에 둘 수 있음.

4.4 Organization › General

URL: [.../organization/{id}](#)

The screenshot shows the 'Organization Settings' page for a 'Default Project'. The left sidebar contains a navigation menu with sections: ACCOUNT (Profile, SSH Key, Integrations), ORGANIZATION (General, Project List, Members, Billing, Cost Analytics), and PROJECT (Default) (General, API Keys, Collaborators, Cost Analytics). The 'General' option under ORGANIZATION is selected. The main content area is titled 'Organization Settings' with the subtitle 'Collaborate in a shared Together account'. It contains three sections: 'Name' with a text input field containing '(org name)' and a 'Save' button; 'Organization ID' with a text input field containing 'org_...'; and 'Date created' with a text input field containing '2023-08-01'. Below these is a 'Privacy' section with two toggle switches: 'Store prompts & responses for product improvements' (set to 'Yes') and 'Allow passthrough models to third-party providers' (set to 'No').

기능 / 필드: 조직명·Organization ID·생성일. Privacy 토글: 프롬프트·응답 저장(제품개선), 서드파티 패스스루 허용.

매핑: 데이터 거버넌스를 조직 단위에서 명시적 토글로 제어 — K-ISMS/내부 정책 대응에 핵심 패턴.

4.5 Organization › Project List

URL: [.../organization/{id}/projects](#)

Default Project ▾

ACCOUNT

Profile

SSH Key

Integrations

ORGANIZATION

General

Project List

Members

Billing

Cost Analytics

PROJECT (Default)

General

API Keys

Collaborators

Cost Analytics

Project List

View organizations, projects, and resources

+ Add project

Project Name	Created	Cost	Collaborators
Default Project	Default Current Jun 23, 2026	\$0.00	1 Manage

기능 / 필드: 테이블 Project Name(Default/Current)·Created·Cost·Collaborators + Manage. '+ Add project'.

매핑: 한 조직이 다수 프로젝트를 두고 프로젝트별 비용·인원을 집계. 우리 Project 엔티티의 상위 컨테이너 구조.

4.6 Organization › Members

URL: [.../organization/{id}/members](#)

Default Project ▾

ACCOUNT

Profile

SSH Key

Integrations

ORGANIZATION

General

Project List

Members

Billing

Cost Analytics

PROJECT (Default)

General

API Keys

Collaborators

Cost Analytics

Members

Manage who has access to your organization

+ Add Member

🔍 Search members by email or name

Name	Email	Role	Added
(redacted) Owner	(redacted)	Admin ▾	

Invitations

Invitations sent via email


Email	Member type	Status	Invited
No invitations found.			

기능 / 필드: Add Member, 이메일/이름 검색, 테이블 Name(Owner)·Email·Role(Admin 등)·Added. Invitations(이메일 초대).

매핑: 조직 레벨 RBAC. Owner/Admin 역할 + 초대 워크플로를 우리 권한 모델에 채택.

4.7 Organization › Billing

URL: [.../organization/{id}/billing](#)




기능 / 필드: Monthly spend, Credit balance(+Add credits), Auto-recharge(임계값 자동충전), Payment method, Invoice·Tax.

매핑: 과금은 조직 단위. Auto-recharge(임계값 기반 자동 크레딧)는 사용량 기반 과금 설계 시 참고.

4.8 Organization › Cost Analytics

URL: [.../organization/{id}/cost-analytics](#)



기능 / 필드: Product/사용량/기간 필터, Daily Cost by Product 차트, Breakdown(Date·Line Item·Qty·Unit Price·Amount) + CSV.

매핑: 제품·라인아이템 단위 비용 분해 + CSV 내보내기. 우리 Cost 대시보드의 표준 구성.

4.9 Project > General

URL: [.../projects/{id}](#)

기능 / 필드: 프로젝트명·Project ID·Slug·생성일. '격리된 워크스페이스' 개념, 기본 프로젝트는 전 멤버 자동 접근.

매핑: Project = 격리 작업공간. Slug/ID 로 리소스 네임스페이싱 — 우리 Project 온톨로지에 직접 대응.

4.10 Project › API Keys

URL: [.../projects/{id}/api-keys](#)

Default Project ▼

API Keys
Create and manage API keys for this project

Key Status
Active ▼

Search by API key ID


Name	ID	Key	Status	Created	Last Used
Legacy API Key	key_...	***b275	Active	6/23	6/23

기능 / 필드: Key Status 필터, Create key, 키 ID 검색, 테이블 Name·ID·Key(마스킹)·Status·Created·Created By·Last Used.

매핑: API 키를 프로젝트 스코프로 격리하고 Last Used 까지 추적. 키 노출 마스킹은 보안 기본값으로 채택.

4.11 Project › Collaborators

URL: [.../projects/{id}/collaborators](#)




기능 / 필드: 검색 + 테이블 Name·Email·Role·Added. 기본 프로젝트는 조직 멤버 자동 접근(제거 불가).

매핑: 프로젝트 범위 접근 제어. 조직 멤버십과 프로젝트 협업자를 2 계층으로 분리한 권한 모델.

4.12 Project › Cost Analytics

URL: [.../projects/{id}/cost-analytics](#)




기능 / 필드: 조직 Cost Analytics와 동일 구조를 프로젝트로 스코프. 'Early Access — 프로젝트 귀속 불완전' 안내.

매핑: 프로젝트 단위 비용 가시성. 멀티프로젝트 환경에서 비용 책임 분배에 유용(단, 귀속 정확도 한계 인지).

5. 인터랙션 기반 상세 확인 (생성 플로우 · 드롭다운 · 옵션)

4 장까지의 화면 분석에 더해, 각 화면의 버튼·드롭다운·생성 폼을 실제로 클릭해 동작과 옵션을 확인했다. 아래는 추정이 아니라 직접 인터랙션으로 관찰한 사실이다. (read-only 계정이라 최종 제출·결제·연동은 실행하지 않았고, 실제 호출/생성 액션은 입금 게이트가 걸린다.)

5.1 Dashboard / 공통 동작



▲ read-only 상태에서 실행 액션 클릭 → 결제 모달 (인터랙션 상태 재구성)

- **태스크 셀렉터:** Quickstart 상단 'Chat ▼'로 태스크 유형 전환. read-only 상태에서 실행성 액션을 누르면 결제 모달('Deposit \$5', 카드번호·만료·CVC·국가 + Skip for now)로 연결된다.
- **코드 스니펫:** Python / TypeScript / curl 토글 + 복사.

5.2 Models — 모델 상세 페이지

Default Project ▼

read-only mode — Make an initial deposit to unlock full access.

Models · Zai Org

GLM 5.2

Zai Org

Chat JSON Mode Tool Calling

</> Run inference Python TS curl

```
from together import Together

client = Together()
response = client.chat.completions.create(
    model="zai-org/GLM-5.2", messages=[...])
```

Author: Zai Org
Released: Jun 17, 2026
External link: Hugging Face
Category: Chat
Parameters: 436.2B
Context length: 262.1K
Pricing: \$1.40 in / \$4.40 out
Deployment: Serverless + Dedicated
Modalities: Text → Text
Features: JSON Mode + Tool Calling

모델 카드 클릭 → 전용 상세 페이지 (메타-Pricing-Run inference 코드)

▲ 모델 카드 클릭 → 전용 상세 페이지 (인터랙션 상태 재구성)

- 카드 클릭 → 전용 상세 페이지: 'Open in Playground', Run inference 코드(Py/TS/curl), 우측 메타 패널 (Author·Released·External link=Hugging Face·Category·Parameters·Context length·Pricing 입력/출력/캐시·Deployment Serverless+Dedicated·Input/Output modalities·Features). 하단에 custom Dedicated Endpoint(B200) 영업 카드.

5.3 Playground — 드롭다운 / 모달

Default Project ▼

read-only mode — Make an initial deposit to unlock full access.

Chat [zai-org/GLM-5.2]

System Prompt...

Model: GLM 5.2 ▼

Search...

Popular Models

- MiniMax M3
- Kimi K2.7 Code
- Deepseek V4 Pro
- GLM 5.1 FP4
- NVIDIA Nemotron 3 Ultra


Chat Models

- Kimi K2.6 Fp4

Browse all models

모델 셀렉터: 검색 + Popular/Chat 카테고리 + Browse all models

▲ 모델 셀렉터 드롭다운 (검색+카테고리) (인터랙션 상태 재구성)



▲ API view 모달 — 설정 반영 라이브 코드 (인터랙션 상태 재구성)

- **모델 셀렉터:** 검색창 + 'Popular Models' / 'Chat Models' 카테고리 + 'Browse all models' 인라인 드롭다운.
- **API view:** 현재 설정이 반영된 라이브 코드 모달(Py/TS/curl). 스트리밍 설정 시 stream=True 와 토큰 루프까지 코드에 반영.
- **파라미터 패널:** Output Length·Temperature(UNSET 토글)·Safety Model·Reasoning·Format Options·Response Format·Functions(+ Add Function)·Sampling.

5.4 Endpoints — 생성 품 자동화 / 옵션

Default Project ▼

△ read-only mode — Make an initial deposit to unlock full access.

Create new endpoint

Model
zai-org/GLM-5-FP4

Display name
jwjinn_4c5c: zai-org - GLM-5-FP4

Hardware
4 x B200-180GB SXM

Min replicas
1 ▼

Availability zone
No preference ▼

Auto-shutdown
Select an option ▼

Speculative decoding
No preference ▼

Max replicas
1 ▼

Summary
Cost based on selected hardware
\$0.797 Per minute hosted
Confirm & deploy

모델 선택 → Display name-Hardware 자동 채움 + '\$/분' 실시간 계산 + 배포 활성화

Hardware는 모델 의존 (GLM-5-FP4 → 4x B200-180GB SXM 단일)

▲ 모델 선택 시 자동 채움 + 실시간 비용 (인터랙션 상태 재구성)

Default Project ▼

△ read-only mode — Make an initial deposit to unlock full access.

Create new endpoint

Model
zai-org/GLM-5-FP4

Hardware
4 x B200-180GB SXM

Availability zone
No preference ▼

Auto-shutdown
Select an option ▼
Disabled ✓
15 minutes
30 minutes
1 hour
3 hours
6 hours
12 hours
24 hours

Summary
Cost based on selected hardware
\$0.797 Per minute hosted
Confirm & deploy

Auto-shutdown: Disabled / 15-30분 / 1-3-6-12-24시간 (유틸 자동 종료)

▲ Auto-shutdown 드롭다운 옵션 (인터랙션 상태 재구성)

- **모델 선택 시 자동 채움:** Display name 자동 생성, Hardware 자동 선택, Summary 가 '\$/분(Per minute hosted)'으로 실시간 계산되고 Confirm & deploy 활성화. 하단에 Create endpoint API 코드(Py/TS/curl) 노출.
- **Hardware 는 모델 의존:** 예) zai-org/GLM-5-FP4 는 '4 x B200-180GB SXM' 단일 옵션만 제공. 모델별로 유효 하드웨어가 제한된다.

- **Auto-shutdown 옵션:** Disabled / 15 분 / 30 분 / 1 시간 / 3 시간 / 6 시간 / 12 시간 / 24 시간 (유휴 자동 종료로 비용 절감).

5.5 Batch jobs — 생성 폼

Default Project ▼

△ read-only mode — Make an initial deposit to unlock full access.

Create batch job

Batch jobs > Create batch job

Input file

Select... ▼ + Upload File

Endpoint

/v1/chat/completions ▼

/v1/chat/completions ✓

/v1/audio/transcriptions

Create job

Batch = Input file(JSONL) + Endpoint(chat/completions-audio/transcriptions)

▲ Batch 생성 + Endpoint 드롭다운 옵션 (인터랙션 상태 재구성)

- **필드:** Input file(선택 또는 Upload) + Endpoint + Create job.
- **Endpoint 옵션:** /v1/chat/completions, /v1/audio/transcriptions (배치는 채팅 완성 + 오디오 전사 지원).

5.6 Fine-tuning — 생성 폼

Default Project ▼

△ read-only mode — Make an initial deposit to unlock full access.

New fine-tuning job

Choose a source

From base model | From previous run | From HF Hub

Choose a model to fine-tune

Select a model ▼

Choose a training file

Select... ▼ | Upload file

Choose a validation file

Select... ▼ | Upload file

Summary

Choose model + dataset for a cost estimate

Create job

Source 3종: From base model / From previous run / From HF Hub

▲ Source 탭 3 종 + 학습/검증 파일 (인터랙션 상태 재구성)

- **Source 탭 3 종:** From base model / From previous run / From HF Hub. (이전 학습 결과 재파인튜닝, HF Hub 모델 가져오기 모두 지원)
- **입력:** Choose a model + Training file + Validation file(각각 선택 또는 Upload, files overview 연결) + 우측 Summary(비용 추정)/Create job. 하이퍼파라미터는 모델·파일 선택 이후 단계에서 노출.

5.7 Evaluations — 생성 마법사

Default Project ▼

△ read-only mode — Make an initial deposit to unlock full access.

Choose a dataset

Select existing dataset or upload .jsonl / .csv to evaluate on

Upload new dataset

Name	Size	Uploaded on	File ID
No datasets — upload to begin			

Use selected dataset

Dataset preview

Verify and preview your uploaded dataset

△ No data available

Evaluations = 데이터셋 우선 마법사 (업로드 + 미리보기 → 평가 유형)

▲ 1 단계 데이터셋 선택 + 미리보기 (인터랙션 상태 재구성)

- 1 단계 **Choose a dataset**: 기존 데이터셋 선택 또는 'Upload new dataset'(.jsonl / .csv). 테이블 Name·Size·Uploaded on·File ID + 'Dataset preview'(검증·미리보기) + 'Use selected dataset'. 데이터셋 우선 마법사이며 평가 유형(Type)은 이후 단계.

5.8 GPU Clusters — 생성 폼 (귀하 작업과 직결)

together.ai

Default Project ▼

△ read-only mode — Make an initial deposit to unlock full access.

Create a new cluster

On-demand Reserved

Cluster details — Pay as you go GPU capacity (hourly)

Cluster Name
Enter a cluster name

Cluster Type
Kubernetes ▼

Region
Select a region ▼

Shared Volume *
▼

Driver Version
570 (CUDA 12.8) ▼

Cluster Add-ons

Autoscaling	Max GPUs	custom OIDC	Traefik
Yes No		Y N	Y N

Preview Cluster

Cluster Type=Kubernetes/Slurm · CUDA 드라이버 · Autoscaling/OIDC/Traefik

▲ 클러스터 생성 폼 (타입·드라이버·Add-ons) (인터랙션 상태 재구성)

together.ai

Default Project ▼

△ read-only mode — Make an initial deposit to unlock full access.

Create a new cluster

On-demand

Cluster Name
Enter a cluster name

Cluster Type
Kubernetes ▼
Kubernetes ✓
Slurm

Region
Select a region ▼


Cluster Type 옵션: Kubernetes / Slurm (둘 다 지원)

▲ Cluster Type 드롭다운 — Kubernetes / Slurm (인터랙션 상태 재구성)


- **과금 탭**: On-demand(시간당 종량제) / Reserved(예약).

- **Cluster Type:** Kubernetes / Slurm 선택 가능.
- **구성 필드:** Cluster Name, Region, Shared Volume(필수), Driver Version(예: 570 / CUDA 12.8).
- **Cluster Add-ons:** Enable Autoscaling(Y/N), Max GPUs, Use custom OIDC(Y/N), Enable Traefik(Y/N). + Estimated Cost, Preview Cluster.
- **시사점:** Kubernetes/Slurm 선택, CUDA 드라이버 버전 지정, 오토스케일·custom OIDC·Traefik 인그레스 토글은 귀하의 kubeadm 베어메탈 + KAI Scheduler 환경의 '클러스터 프로비저닝 UX'에 거의 1:1로 대응. 특히 OIDC·Traefik을 생성 시 옵션으로 노출하는 패턴을 참고할 만하다.

5.9 Analytics — Group By / Errors



▲ Group By 드롭다운 옵션 (인터랙션 상태 재구성)




▲ Errors 탭 — HTTP 코드별 카드 (인터랙션 상태 재구성)

- **Group By 옵션:** None / Model / Usage Type / Api Key / Deployment (API 키·배포 단위 비용/사용량 분해 가능).
- **Errors 탭:** HTTP 상태코드별 카드 — Bad request(400) / Unauthorized(401) / Resource not found(404) / Rate limited(429) 등 시계열 Count. 오류를 코드 단위로 모니터링.

5.10 드롭다운 전체 옵션 (펼쳐서 확인한 셀렉트 목록)

read-only 로 막히지 않는 셀렉트들을 모두 펼쳐 옵션을 확인했다. (GPU 타입 전체 목록은 이 품에 없고 'Preview Cluster' 단계에서 선택되며, 해당 단계는 입금 게이트로 미확인. Reserved 탭은 존재하나 이 계정에선 품이 활성화되지 않음 — 영업 게이팅 추정.)



GPU Clusters — Driver Version

CUDA 드라이버 버전 선택

Driver Version

570 (CUDA 12.8) ▼

550 (CUDA 12.4)
555 (CUDA 12.5)
560 (CUDA 12.6)
565 (CUDA 12.6)
570 (CUDA 12.8) ✓
575 (CUDA 12.9)

550~575 / CUDA 12.4~12.9.

570(CUDA 12.8) 기본.

- **Endpoints · Availability zone:** No preference, us-east-1a, ca-east-1a, us-central-4a, ca-west-1b, eu-north-1b, eu-central-1a, us-south-3a, us-central-4b, us-central-6a, us-east-3a, us-east-4a ... (US·캐나다·EU 다지역, 스크롤로 더 있음).
- **Endpoints · Auto-shutdown:** Disabled / 15 분 / 30 분 / 1 시간 / 3 시간 / 6 시간 / 12 시간 / 24 시간.
- **Endpoints · Min/Max replicas:** 1, 2, 3 ... 11+ (정수 선택, 오토스케일 범위).

GPU Clusters — Region

클러스터 리전 (일부 비활성)


Region

Select a region ▼

us-central-8
us-central-7
ca-west-1
us-central-4 ✓
us-east-3

일부 리전은 회색(미가용).

가용 리전만 선택 가능.



- **GPU Clusters · Cluster Type:** Kubernetes / Slurm.
- **GPU Clusters · Region:** us-central-8, us-central-7, ca-west-1, us-central-4, us-east-3 ... (일부 리전은 비활성/회색, 가용 리전만 선택).
- **GPU Clusters · Driver Version:** 550(CUDA 12.4) / 555(12.5) / 560(12.6) / 565(12.6) / 570(12.8, 기본) / 575(12.9).
- **GPU Clusters · 과금 탭:** On-demand(시간당) / Reserved(예약, 이 계정에선 비활성).
- **Playground · Response Format:** JSON / Text.
- **Playground · Reasoning:** Model Default / Disabled / Low Effort / Medium Effort / High Effort.
- **Batch · Endpoint:** /v1/chat/completions, /v1/audio/transcriptions.
- **Analytics · Group By:** None / Model / Usage Type / Api Key / Deployment. 기간 = N(예 24) × 단위(Hours 등).

시사점: 리전·가용존이 US·캐나다·EU 에 걸쳐 있고 CUDA 드라이버 버전을 사용자가 선택하게 한 점, Reasoning effort 를 단계로 노출한 점은 우리 플랫폼의 배포 옵션·리전 전략·추론 제어 UX 설계에 참고할 만하다.

6. 기능 인벤토리 (요약)

영역	화면/메뉴	제공 기능 핵심
탐색	Models	모델 카탈로그(카드+테이블), 기능 태그, Serverless/Dedicated 필터, 분해 단가, 비교, 커스텀/업로드
실험	Playground	파라미터 패널(Temp·Length·Reasoning·Response Format·Functions), Presets, Safety Model, API view 코드화
서빙	Endpoints	전용 엔드포인트 생성(모델·하드웨어·오토스케일·자동종료·비용추정) 및 목록 관리(Name/Status/Hardware/Pricing)
서빙	Batch jobs	비동기 대량 배치 추론(할인가), Files 입력+모델 지정, 잡 상태 추적(ID/Input file/Model/Status)
서빙	Containers	커스텀 컨테이너/추론엔진 배포(CLI 3 단계), List of deployments(Name/Status/Image/Scaling/GPU), 엔터프라이즈 게이팅

영역	화면/메뉴	제공 기능 핵심
학습	Fine-tuning jobs	파인튜닝 잡 생성/목록, 상태·메서드 필터, Base Model·Suffix·Method 추적
학습	Evaluations	평가 실행/추적(Name/Status/Dataset/Type/Date), 상태·유형 필터, 데이터셋 1 급 입력
인프라	GPU Clusters	베어메탈/전용 GPU 클러스터 예약·관리, Clusters/Cluster Storage 탭, 예약기간·머신수·리전 컬럼, 콘솔+CLI
데이터	Files	입력 파일 업로드/검색/관리(File ID/Filename/Status/Size), FT·Batch·Eval 공유 저장소
운영	Analytics	Usage/Errors, Group By·기간 필터, Requests·TPS·In/Out tokens 시계열(집계방식 라벨)
거버넌스	Settings	Account/Organization/Project 3 계층, Billing·Cost Analytics, API Keys(프로젝트 스코프), Members·Collaborators, SSH Key·Integrations

전체 13 개 화면을 직접 접속·관찰하여 작성. (Settings 의 개인정보 필드는 보고서에서 제외)

7. 제품 개발 시사점 (정리)

- **단일 동선:** Models(탐색) → Playground(시험·코드화) → Endpoint(배포) → Analytics(관제)가 끊김 없이 이어진다. 우리 콘솔도 이 4 단계를 1 급 동선으로 설계.
- **카탈로그 메타데이터 표준화:** 모델 카드 = 기능 태그 + 배포유형 배지 + 분해 단가(입력/출력/캐시). 카드 (탐색)와 테이블(비교) 이중 뷰.
- **엔드포인트 생성 폼:** 모델 → 하드웨어 의존 활성화, Min/Max replica 오토스케일, Auto-shutdown, 그리고 항상 보이는 실시간 비용 Summary + 배포 버튼.
- **코드 우선 온보딩:** 로그인 직후 복붙 가능한 첫 호출 코드(언어 토글) 노출. 빈 상태에도 설명 + 단일 CTA.
- **관제 카드:** Requests/TPS/In-Out tokens 를 집계 방식 라벨과 함께 시계열로. 여기에 우리 강점인 Dynamo TTFT/ITL 히스토그램, DCGM GPU 지표(util·메모리·온도·전력)를 더해 차별화.
- **셀프서비스 ↔ 영업 분기:** 소규모는 셀프 배포, 대규모는 'Contact sales'로 분기하는 카드를 각 목록 화면 하단에 배치.
- **어휘 정렬:** 마케팅 메시지와 콘솔 메뉴가 같은 어휘(Inference/Model Shaping)를 공유. 우리 온톨로지 용어도 외부·내부 일관성 확보.
- **거버넌스 2 계층(Org/Project):** 과금·데이터정책·멤버는 조직 레벨, API 키·협업자·작업공간은 프로젝트 레벨로 분리하고 Cost Analytics 는 양 레벨에 중복 제공. 데이터 저장/패스스루를 조직 토글로 제어하는 패턴은 K-ISMS·내부 보안정책 대응에 직접 활용 가능.